

NOMES DO(S) ALUNO(S) PARTICIPANTE(S):		RA	CURSO
1. <i>Vinicius Motta Garcia</i>		240036	11
DISCIPLINA: EA018			
ORIENTADOR: Prof. Dr. Fernando José Von Zuben			
TEMA DO PROJETO: Aplicações de Deep Metric Learning para Visualização e Representação de Dados			
RESUMO DO CRONOGRAMA DAS ATIVIDADES.			
PERÍODO DE REALIZAÇÃO:		DESCRIÇÃO**:	
Agosto	Setembro	Revisão da literatura em deep metric learning.	
Setembro	Outubro	Formalização dos principais conceitos	
Outubro	Dezembro	Mapeamento das principais metodologias.	
Dezembro	Janeiro	Definição e implementação de casos de estudo	
Janeiro	Fevereiro	Comparação com métodos tradicionais de projeção	
Fevereiro	Março	Exploração das análises e propostas de extensões	
Março	Abril	Avaliação dos resultados e organização das análises	
Abril	Julho	Escrita e finalização da monografia	

DATA: 09/11
OBSERVAÇÕES: No cronograma apresentado acima, é apresentado uma versão preliminar das etapas pretendidas também para EA019, as quais ainda podem ser revistas.

* Para trabalhos em grupo cada participante deverá apresentar separadamente o formulário preenchido.

INTRODUÇÃO:

O campo de *Machine Learning* tem se expandido de forma significativa nas últimas décadas, sendo aplicado com sucesso em uma ampla variedade de tarefas, especialmente em problemas de classificação. Tradicionalmente, esses métodos dependiam fortemente de processos de *feature engineering*, nos quais especialistas precisavam projetar manualmente as características relevantes para cada tarefa específica [1]. No entanto, o avanço das redes neurais profundas (*Deep Learning*) transformou esse paradigma ao permitir que os próprios modelos aprendam representações úteis diretamente dos dados brutos, reduzindo a necessidade de intervenção humana e melhorando a generalização dos modelos [2].

Apesar desses avanços, as técnicas de *Deep Learning* ainda enfrentam limitações quando aplicadas em cenários de *few-shot* e *one-shot learning*, nos quais há poucas amostras disponíveis por classe. Nessas situações, modelos supervisionados tradicionais tendem a apresentar baixo desempenho devido à sua alta dependência de grandes volumes de dados rotulados. Uma abordagem promissora para lidar com essa limitação é o *Deep Metric Learning* (DML), que visa aprender representações (ou *embeddings*) baseadas em medidas de similaridade entre amostras.

O *Deep Metric Learning* busca projetar amostras em um espaço vetorial de forma que exemplos de uma mesma classe fiquem próximos entre si, enquanto exemplos de classes distintas sejam afastados. Essa propriedade o torna especialmente eficaz em tarefas como reconhecimento facial, verificação de assinaturas e recuperação de imagens, nas quais é necessário comparar pares ou grupos de amostras em vez de realizar uma simples classificação.

Entre as principais técnicas de DML destacam-se as redes siamesas com *contrastive loss*, a *FaceNet* com *triplet loss*, e métodos mais recentes como o *SimCLR*, que introduz princípios de aprendizado contrastivo auto-supervisionado, permitindo o aprendizado de representações robustas mesmo sem rótulos explícitos [3]. Assim, o presente trabalho propõe a implementação e comparação dessas abordagens em diferentes conjuntos de dados (como MNIST e CIFAR-10), com o objetivo de analisar o comportamento e a eficácia relativa de cada técnica em contextos variados.

OBJETIVOS:

O principal objetivo deste trabalho é comparar diferentes abordagens de *Deep Metric Learning*, analisando sua capacidade de aprender representações discriminativas e eficientes em diferentes conjuntos de dados. Para isso, serão estudadas e implementadas técnicas clássicas e recentes da área, incluindo a *Contrastive Loss* aplicada em redes siamesas, a *Triplet Loss* utilizada na *FaceNet*, e o *SimCLR*, considerado um dos métodos mais modernos de aprendizado contrastivo. Opcionalmente, poderá ser incluída também outras técnicas modernas ou tradicionais, de forma a ampliar o escopo comparativo entre abordagens.

Os experimentos serão conduzidos utilizando a biblioteca PyTorch, com arquiteturas baseadas em redes neurais convolucionais (CNNs) para garantir consistência nas comparações. Inicialmente, os testes serão realizados em conjuntos de dados amplamente utilizados na literatura, como MNIST e CIFAR-10, podendo ser estendidos a bases mais desafiadoras conforme o andamento do projeto. A avaliação das representações obtidas será feita tanto de forma qualitativa, por meio de técnicas de visualização como t-SNE, PCA e UMAP, quanto de forma quantitativa, utilizando métricas como *Accuracy*, *Recall*.

Além disso, pretende-se analisar o custo computacional de cada técnica, considerando aspectos como tempo de treinamento, estabilidade e convergência dos modelos. Por fim, o trabalho também pretende explorar tendências recentes da área, como o uso de arquiteturas baseadas em

Transformers e métodos de *Self-Supervised Learning*, que poderão ser investigados como possíveis extensões futuras do estudo.

CRONOGRAMA DE ATIVIDADES DETALHADO:

Até o mês de novembro de 2025, foram concluídas as etapas iniciais do projeto, que compreenderam a revisão da literatura, a formalização dos conceitos teóricos e o mapeamento das principais metodologias de *Deep Metric Learning*. Nesse período, foi desenvolvida uma base teórica sólida sobre os fundamentos do aprendizado de métricas, com ênfase nas técnicas *Contrastive Loss*, *Triplet Loss* e *SimCLR*. Além disso, foram definidos os principais objetivos experimentais, as métricas de avaliação e os conjuntos de dados que serão utilizados, estabelecendo as diretrizes para a fase prática do projeto.

A partir de dezembro de 2025, inicia-se a etapa de definição e implementação dos casos de estudo, que envolverá a construção e o treinamento dos modelos utilizando a biblioteca PyTorch. Serão implementadas arquiteturas baseadas em redes neurais convolucionais (CNNs) para cada técnica selecionada, assegurando um ambiente experimental consistente. Nessa fase, também serão realizados os primeiros testes com os datasets MNIST e CIFAR-10, visando validar a implementação e ajustar os hiperparâmetros necessários para o bom desempenho dos modelos.

Durante janeiro e fevereiro de 2026, será realizada a comparação com métodos tradicionais de projeção, como PCA, t-SNE e UMAP. O objetivo dessa etapa é avaliar a qualidade das representações obtidas pelas técnicas de *Deep Metric Learning*, tanto de forma qualitativa, através da visualização dos *embeddings*, quanto quantitativa, por meio de métricas como Acurácia e *Recall*. Essa fase também incluirá a análise do custo computacional, considerando tempo de treinamento, convergência e eficiência de cada abordagem.

Entre fevereiro e março de 2026, será realizada a exploração das análises e propostas de extensões, etapa dedicada à investigação de possíveis aprimoramentos dos modelos implementados e à discussão de tendências recentes na área, como o uso de arquiteturas baseadas em *Transformers* e técnicas de *Self-Supervised Learning*. Essa fase poderá resultar em novas direções para experimentos complementares ou ajustes finos nas implementações existentes.

Nos meses de março e abril de 2026, ocorrerá a avaliação consolidada dos resultados e organização das análises, com foco na integração dos dados experimentais, comparação detalhada entre as diferentes técnicas e preparação dos resultados para apresentação formal.

Por fim, entre abril e julho de 2026, será conduzida a etapa de escrita e finalização da monografia, que abrangerá a sistematização dos resultados, a discussão crítica dos achados e a elaboração das conclusões, onde o texto final será estruturado.

RESULTADOS ESPERADOS:

Espera-se que a execução deste projeto resulte em uma análise comparativa detalhada entre diferentes técnicas de *Deep Metric Learning*, fornecendo uma visão clara sobre suas vantagens, limitações e adequação a diferentes tipos de dados. Inicialmente, espera-se confirmar que as abordagens clássicas, como as redes siamesas com *Contrastive Loss* e a *FaceNet* com *Triplet Loss*, apresentam bom desempenho em cenários supervisionados e de baixa complexidade, como o dataset MNIST, sendo capazes de gerar *embeddings* bem estruturados e com boa separabilidade entre classes.

Por outro lado, técnicas mais recentes, como o *SimCLR*, devem demonstrar maior capacidade de generalização e robustez, especialmente no dataset CIFAR-10, que apresenta maior variabilidade

intra e interclasse. Espera-se que esses métodos produzam representações mais ricas e compactas, mesmo com menor dependência de rótulos explícitos, evidenciando o potencial das abordagens contrastivas modernas em contextos de *self-supervised learning*.

Do ponto de vista quantitativo, espera-se observar diferenças significativas nas métricas de desempenho, como *Accuracy*, *Recall*, refletindo o impacto das funções de perda e das estratégias de treinamento adotadas em cada técnica. Já na análise qualitativa, as projeções obtidas por meio de PCA, t-SNE e UMAP deverão evidenciar uma melhor organização das classes no espaço de representação, indicando a eficiência do aprendizado de métricas no agrupamento de amostras similares.

Além dos resultados de desempenho, o projeto também deverá fornecer uma análise sobre o custo computacional e a eficiência de cada método, considerando fatores como tempo de convergência, estabilidade de treinamento e consumo de recursos. Espera-se que métodos mais recentes, embora potencialmente mais custosos em termos computacionais, ofereçam melhor desempenho em tarefas de generalização e transferibilidade.

Como resultado final, o trabalho deverá consolidar uma avaliação comparativa abrangente entre as técnicas estudadas, servindo como base para futuras investigações na área de *representation learning* e abrindo espaço para a exploração de abordagens ainda mais modernas, como modelos baseados em *Transformers* e métodos *multi-modal*. Espera-se, assim, que o estudo contribua tanto para a compreensão prática quanto teórica das potencialidades do *Deep Metric Learning* na representação e visualização de dados complexos.

REFERÊNCIAS BIBLIOGRÁFICAS:

- [1] MOHAN, Deen Dayal; JAWADE, Bhavin; SETLUR, Srirangaraj; GOVINDARAJ, Venu. *Deep Metric Learning for Computer Vision: A Brief Overview*. arXiv preprint arXiv:2312.10046, 2023. Disponível em: <https://doi.org/10.48550/arXiv.2312.10046>.
- [2] AGRAWAL, Aakash. *The Why and the How of Deep Metric Learning*. TDS Archive – Medium, 2020.
- [3] CHEN, Ting et al. *A Simple Framework for Contrastive Learning of Visual Representations*. In: *International Conference on Machine Learning (ICML)*. Proceedings of Machine Learning Research (PMLR), 2020, p. 1597–1607.